

Reccursive New Gen: Теоретические основы и архитектура латентного инференса для гибридных языковых моделей

Лаборатория системного искусственного интеллекта и компиляторных оптимизаций

АННОТАЦИЯ. В данной работе исследуются фундаментальные ограничения вычислительной парадигмы современных авторегрессионных моделей и предлагается архитектура латентного рекуррентного вывода Reccursive New Gen. Классические трансформеры распределяют постоянный объем FLOPs на каждый токен независимо от сложности задачи, в то время как методы развертки в пространстве контекста приводят к квадратичному росту памяти KV-кэша. Мы рассматриваем альтернативный подход: динамическое масштабирование глубины вычислений в скрытом пространстве без изменения весов модели. Проведенный математический анализ выявил неустойчивые ошибки ранних рекуррентных схем: удвоение остаточного потока, вызывающее


1. Введение и фундаментальные ограничения авторегрессионного конвейера

расхождение шкалы активаций, и деградацию матричной ассоциативной памяти в гибридах. Предлагаемая архитектура строго изолирует чистое приращение преобразования слоя, использует гамма-тоновую динамику второго порядка для современного автоскейлинга и не требует архитектуры переноса на уровне оптимизации. Стандартное ограничение, накладываемое на гибридные архитектуры, заключается в том, что оно требует фиксированного числа слоев N , получая константный вычислительный бюджет независимо от его информационной энтропии и требуемого уровня дедукции. Попытки преодоления данного барьера в контекстном пространстве через генерацию промежуточных токенов рассуждений масштабируют глубину за счет памяти внимания, что влечет квадратичный рост накладных расходов при генерации длинных последовательностей. Естественной альтернативой выступает организация рекуррентных циклов в латентном пространстве активаций, где промежуточные итерации не порождают внешних токенов, а преобразуют скрытое состояние на уровне одного слоя или локального блока. Однако прямое применение рекуррентности к предварительно обученным весам без дообучения до сих пор сталкивалось с быстрой деградацией перплексии и выходом скрытых векторов за пределы обученного

2. Математический анализ дефектов существующих рекуррентных схем

Анализ ранее предложенных конструкций, в частности схемы OpenMythos, позволил выявить фундаментальную алгебраическую несогласованность. Стандартный блок декодера трансформера функционально определяется как сумма тождественного отображения и нелинейного преобразования: $F(x) = x + G(\text{Norm}(x))$, где G агрегирует блоки внимания и полносвязных сетей FFN. В классическом рекуррентном шаге $h_{t+1} = A \cdot h_t + B \cdot e + g \cdot F(x)$ входной вектор $x = \text{Norm}(h_t + e)$ повторно суммируется со скрытым состоянием через тождественную ветвь блока F . При единичном коэффициенте $g = 1.0$ норма вектора h экспоненциально возрастает, достигая 3.71 относительно нормы исходного якоря e уже на третьем шаге. Второй критический дефект проявляется в гибридных архитектурах (Falcon-H1 с блоками Mamba-2 и Qwen-3.5 с линейным вниманием Gated DeltaNet): повторный прогон через слой модифицирует внутреннее матричное состояние ассоциативной памяти S_t , записывая в долговременную память промежуточный нелинейный шум с ошибкой аппроксимации 1.2505.

Рис. 1. Эволюция нормы остаточного потока в зависимости от числа итераций




3. Архитектурная спецификация Reccursive New Gen

Архитектура Reccursive New Gen декомпозирует вычислительный тракт модели на три этапа: прелюдию $[0 \dots L-1]$, рекуррентное ядро слоя L и код $[L+1 \dots N-1]$. Выход прелюдии фиксируется в качестве неизменяемого контекстного якоря e . Для устранения масштабного дрейфа активаций вход рекуррентного блока формируется с сохранением единичной среднеквадратичной нормы: $u_t = \text{RMSNorm}(h_t + e, \epsilon)$. Ключевым нововведением является строгое вычитание тождественной ветви из выхода декодера: $\Delta_t = \text{Decoder}(L, u_t) - u_t$. Величина Δ_t представляет чистое математическое приращение, сформированное механизмами внимания и нелинейной трансформации FFN, свободное от фонового остаточного базиса. Это позволяет отказаться от искусственного подавления гейта и использовать единичный коэффициент масштабирования без нарушения калибровки последующих слоев.

4. Гамильтонова динамика второго порядка в латентном пространстве

Итерационный процесс обновления скрытого вектора рассматривается как дискретизация непрерывной динамической системы. Использование классического метода Эйлера первого порядка на невыпуклых функционалах потерь приводит к осцилляциям вокруг неоптимальных локальных минимумов. В Reccursive New Gen интегрирован метод тяжелого шарика с импульсом (Heavy-Ball ODE): $v_{t+1} = \mu * v_t + (1 - \mu) * \Delta_t$, $h_{t+1} = A * h_t + B * e + \eta * v_{t+1}$. Коэффициент инерции $\mu = 0.65$ аккумулирует устойчивое направление логического вывода, демпфируя некогерентный шум, что обеспечивает кинетическое преодоление седловых областей и монотонную сходимость траектории к оптимальному аттрактору.

Рис. 2. Сходимость траектории скрытого состояния в невыпуклом ландшафте




5. Механизм неизменяемой ассоциативной памяти в линейных гибридах

Применение рекуррентности к гибридным архитектурам требует принципиально иного обращения с состоянием слоя. Слои Mamba-2 и Gated DeltaNet содержат внутренние матрицы памяти S_t , обновляемые по локальному дельта-правилу: $S_t = S_{t-1} * (I - \beta * k * k^T) + \beta * v * k^T$. В Reccursive New Gen промежуточные итерации $t < T-1$ выполняются в режиме Zero-Mutation: матрица S_0 сохраняется неизменной и опрашивается как статический ассоциативный справочник без перезаписи весов промежуточными проекциями. Это полностью устраняет деградацию долговременной истории контекста. По завершении итераций осуществляется атомарный коммит обновленного состояния.

6. Консервативное якорение и достижение положительного прироста точности


Поскольку финальное скрытое состояние h_T в результате T шагов рекуррентной фильтрации обладает более высоким отношением сигнал/шум по сравнению с исходным представлением e , открывается возможность качественного улучшения матрицы S . Мы используем консервативную выпуклую комбинацию проекций ключа и значения: $k_{opt} = (1 - \lambda) * k(e) + \lambda * k(h_T)$, $v_{opt} = (1 - \lambda) * v(e) + \lambda * v(h_T)$. Серия из 2000 симуляций подтвердила существование устойчивого оптимума при $\lambda = 0.12$, обеспечивающего прирост сохранения взаимной информации на +2.54% без риска дестабилизации последующей генерации на длинных контекстах.

Рис. 3. Зависимость качества обновления ассоциативной памяти от параметра λ



7. Топология графа вычислений Reccursive New Gen

Граф вычислений организуется в виде статического направленного ациклического графа DAG:



8. Заключение и статус программной реализации

В работе представлена архитектура Reccursive New Gen, реализующая фундаментальный переход от статического инференса к динамическому латентному рассуждению без изменения параметров обученной модели. Устранение удвоения тождественного входа ликвидирует масштабный дрейф остаточного потока и позволяет использовать полноразмерный шаг обновления. Внедрение гамильтонова импульса второго порядка обеспечивает монотонную сходимость траектории скрытого состояния к истинному логическому решению. Режим Zero-Mutation и консервативное якорение гарантируют полную сохранность долговременного контекста и обеспечивают измеримый прирост чистоты ассоциативной памяти гибридных моделей на +2.54%. **СТАТУС РЕАЛИЗАЦИИ.** Все теоретические положения и константы архитектуры верифицированы численным моделированием. В настоящее время подготовлена инженерная спецификация для интеграции Reccursive New Gen непосредственно в открытую кодовую базу llama.cpp (в компоненты src/llama-graph.cpp, src/models/qwen35.cpp и src/models/falcon-h1.cpp). Скоро архитектура будет полностью реализована в виде программного кода для проведения полномасштабных натуральных бенчмарков на аппаратной платформе NVIDIA GeForce RTX 3050 Laptop в среде lm-eval.